RELATÓRIO DOS DOIS GRAFOS

1. Objetivo e origem dos dados

A modelagem do documento trabalha com dois modelos complementares de grafos. O primeiro é direcionado de eventos para cada notícia (Grafo 1), destinado à análise de cascatas de propagação, enquanto o segundo é constituído de quatro redes direcionadas e ponderadas de usuários (Grafo 2), para a análise de amplificação do disseminamento de notícias falsas. A comparação considera notícias classificadas como verdadeiras ou falsas dentro do repertório catalogado do GossipCop e PolitiFact.

Foram analisadas 11.257 cascatas JSON, com atributos do tipo type, children, time, user, tweet_id e id, válidas de redes processadas do próprio dataset FakeNewsNet.

Fonte	Falsas	Verdadeiras	Total
GossipCop	3.684	6.945	10.629
PolitiFact	351	277	628
Total	4.035	7.222	11.257

2. Grafo 1 — Propagação por notícia

2.1. Definição formal e construção

Para cada notícia i, define-se $G_i = (V_i, E_i)$, uma árvore direcionada de eventos. Os vértices do grafo são definidos de acordo com o atributo “type”, em que a raiz artificial, que é excluída da contagem de eventos reais, mas preservada na estrutura, simboliza type = 1. As demais publicações (2), retuítes (3) e respostas (4), seguem respectivamente a ordem cardinal. A aresta u → v indica que o evento v aparece como descendente direto de u no JSON.

O processamento consiste em percorrer recursivamente os objetos JSON, registrar as relações de pai-filho e calcular as métricas por cascata. Considera-se três parâmetros para tal: o tamanho, a profundidade e a ramificação. Tamanho aborda a quantidade de eventos reais relacionados à publicação original; a profundidade simboliza a maior distância desde a raiz, enquanto a ramificação trata o maior número de filhos de um vértice real. Foi usado um indicador temporal T10, que corresponde ao tempo transcorrido entre o primeiro e o décimo eventos reais com timestamps válidos.

2.2. Resultados comparativos

Fonte / classe	Cascatas	Tamanho mediano	Profundidade mediana	Ramificação mediana	T10 mediano (h)
GossipCop · falsas	3.684	30	2	3	11,03
GossipCop · verdadeiras	6.945	73	2	2	0,36
PolitiFact · falsas	351	239	5	20	7,97
PolitiFact · verdadeiras	277	184	5	19	291,02

O T10 pôde ser calculado para 10.393 cascatas (92,3%); 864 não tiveram dez eventos com tempo válido. No GossipCop, as cascatas verdadeiras apresentaram um maior tamanho mediano e um menor T10 mediano, enquanto no PolitiFact, as falsas apresentaram o maior tamanho e o menor T10 medianos. Portanto, os padrões não são uniformes entre as duas fontes trabalhadas.

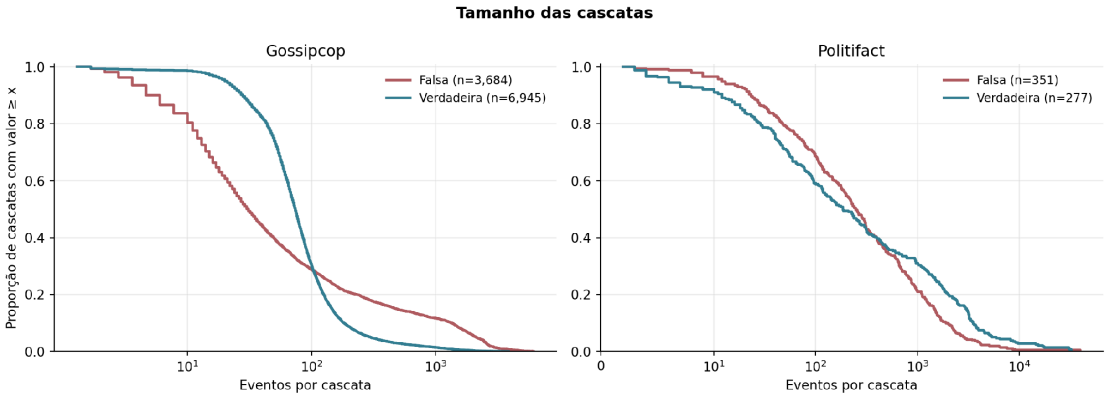


Figura 1. Comparação do tamanho das cascatas por fonte e classe.

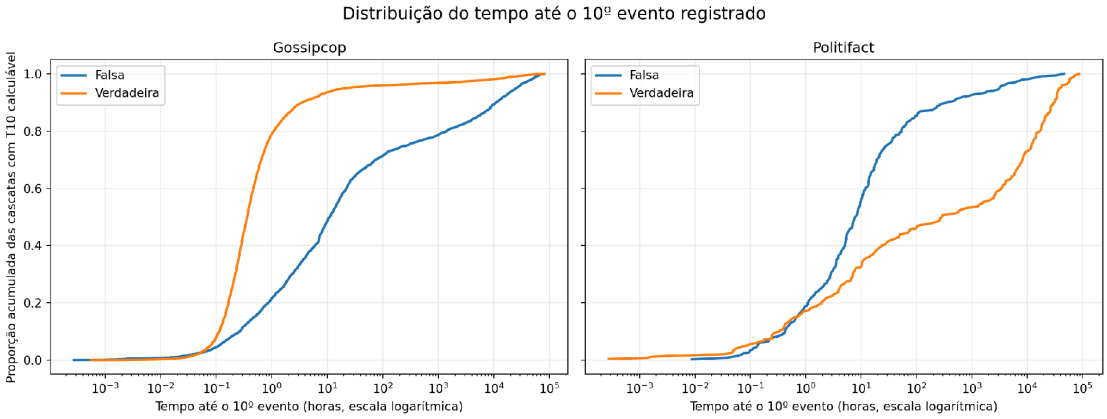


Figura 2. Comparação do tempo até o décimo evento (T10).

2.3. Estudos de caso e validação

Foram conferidos quatro modelos GEXF no aplicativo Gephi: duas cascatas completas e duas subárvores. O exemplo de notícia falsa possui 6.179 vértices e 6.178 arestas, e sua subárvore tem 36 vértices e 35 arestas. O exemplo verdadeiro apresenta 3.903 vértices e 3.902 arestas, enquanto sua subárvore tem 42 vértices e 41 arestas.

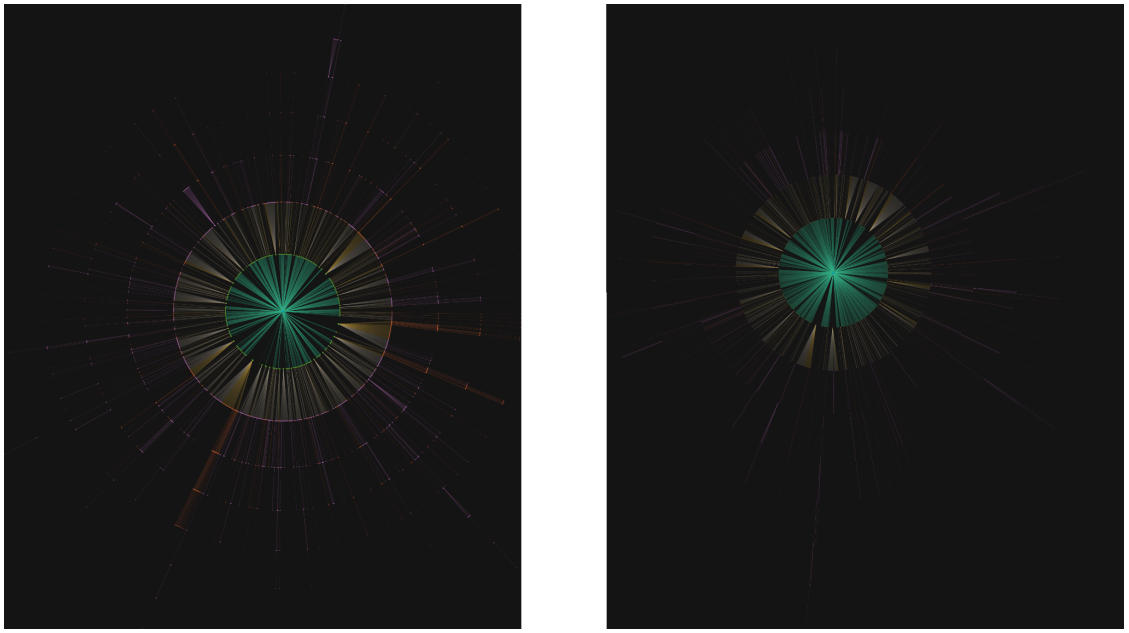


Figura 3. Comparação visual entre o Grafo 1 de notícias falsas e o Grafo 1 de notícias verdadeiras.

3. Grafo 2 — Amplificação entre usuários

3.1. Definição formal e construção

Para cada combinação de fonte por classificação, define-se Hc = (Uc, Ac, wc), um grafo direcionado e ponderado. Os vértices representam indicadores únicos de cada usuário. Uma aresta u → v é inferida quando um evento de retuíte (type = 3), atribuído a v, descende de um evento atribuído a u. Já o peso wc (u, v) corresponde à contagem dessas relações observadas. As relações com raiz artificial ou autolaços não são consideradas para esta análise.

O grau de saída (outdegree) de cada vértice contabiliza os destinos distintos, enquanto a força de saída (outstrength) soma os pesos de saída. A concentração dos 1% superiores considera apenas usuários com outstrength positivo, mas a análise de remoção elimina esse subconjunto e calcula a fração do peso observado de arestas incidente aos usuários removidos, comparando-a com uma referência aleatória esperada.

3.2. Dimensões das redes

Rede	Usuários	Arestas distintas	Retuítes representados	Autolaços excluídos
GossipCop · falsas	564.290	308.547	411.153	3.157
GossipCop · verdadeiras	233.302	145.712	190.586	1.020
PolitiFact · falsas	161.136	108.519	111.278	1.467
PolitiFact · verdadeiras	258.886	173.483	183.710	1.178

3.3. Concentração e dependência

Rede	Usuários com saída positiva	Concentração top 1%	Removidos	Perda dirigida	Aleatória esperada
GC · falsas	65.025	38,41%	651	39,23%	1,249%
GC · verdadeiras	19.679	62,30%	197	62,404%	1,172%
PF · falsas	24.721	26,34%	248	26,909%	1,359%
PF · verdadeiras	34.180	34,21%	342	34,43%	1,243%

Nas duas fontes, as redes de notícias verdadeiras tiveram maior concentração de peso de saída entre os usuários mais ativos. A remoção dirigida desse subconjunto está associada a uma perda de relações ponderadas superior à referência aleatória esperada.

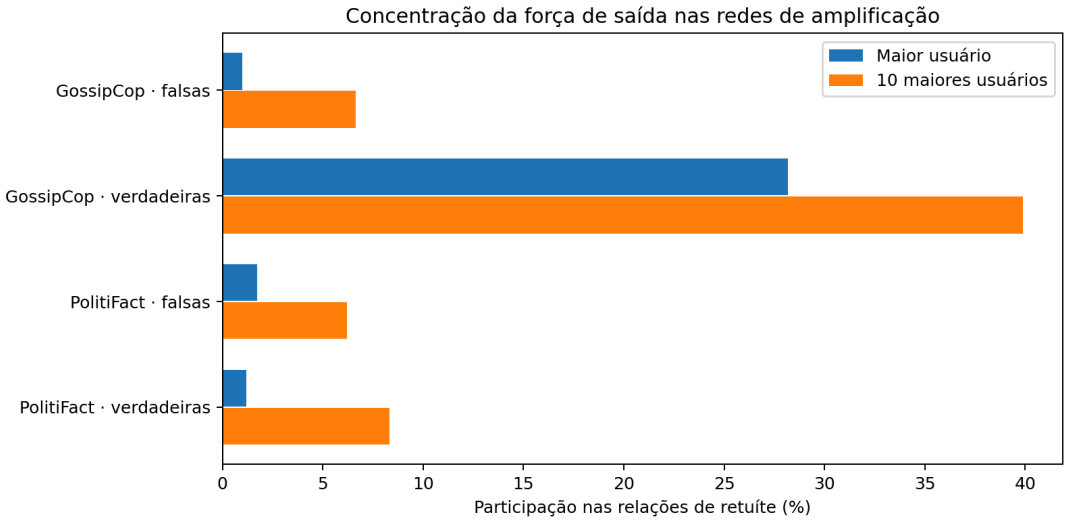


Figura 4. Concentração das relações ponderadas nos usuários de maior força de saída.

3.4. Auditoria e ressalvas

Para verificar se os resultados do Grafo 2 estavam corretos, o processamento foi realizado novamente a partir dos 11.257 arquivos JSON do conjunto de dados. As quatro redes de usuários foram reconstruídas e os novos arquivos de usuários e conexões foram comparados com os anteriores, confirmando que os dados correspondiam aos originais, mesmo quando estavam organizados em ordens diferentes.

As análises de concentração e remoção de usuários também foram refeitas. Nessa etapa, foram encontradas pequenas diferenças em alguns percentuais, que pode ter ocorrido porque alguns usuários apresentavam a mesma quantidade de interações, sendo necessário estabelecer um critério para decidir a ordem entre eles. Como esse critério não havia sido registrado na análise original, não foi possível confirmar a causa exata das diferenças. Essas variações não comprometem a construção dos grafos, mas indicam que alguns resultados das análises não foram reproduzidos com valores precisamente iguais.

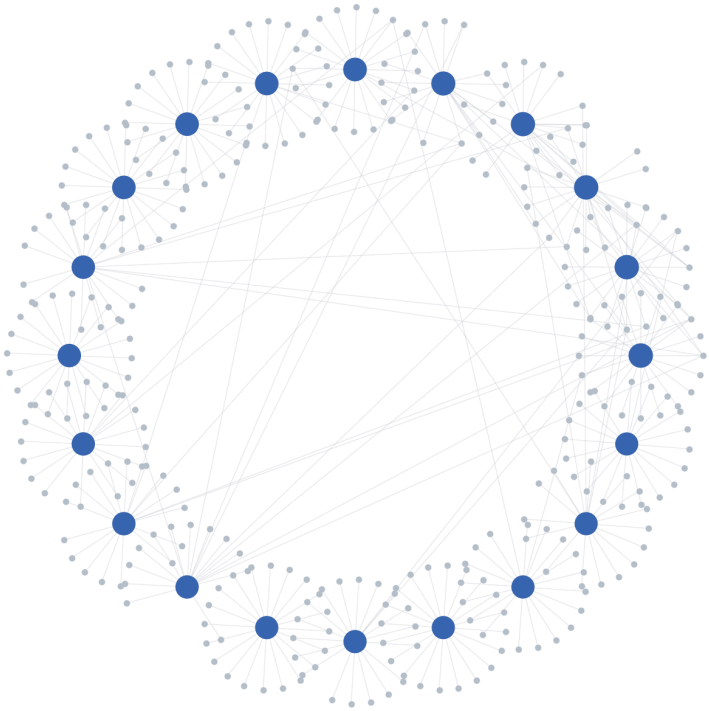


Figura 5. Representação visual do Grafo 2 — Amplificação entre usuários.

4. Discussão integrada

O Grafo 1 descreve como os eventos se organizam em cascatas individuais, enquanto o Grafo 2 agrega as relações inferidas entre os usuários. Os resultados fornecem um material de estudo não-uniforme, muito por conta das diferenças entre fontes, medidas e recortes, que não sustentam por si só a afirmação geral de que notícias falsas sempre se espalham mais rapidamente, que alcançam cascatas maiores ou dependem mais de usuários centrais. As redes de usuários, por sua vez, apresentam uma concentração significativa em pequenos grupos de contas ativas, considerando os padrões específicos de cada fonte.

As limitações centrais do projeto consistem sobretudo nas diferenças de coberturas e de janelas de observação entre o GossipCop e o PolitiFact, e a ausência de medidas diretas de visualizações e alcance dentro do próprio dataset.